有限オートマトンと正規表現

離散数学・オートマトン
2024 年後期
佐賀大学理工学部　只木進一

1. **正規表現**: Regular expressions
2. **正規表現と有限オートマトン**: Regex and FA
3. **正規表現から DFA へ**: From Regex to DFA
4. **有限オートマトンの受理言語を正規表現で構成**: From FA to Regex
5. **正規表現に対する反復補題**

正規表現: Regular expressions

- 文字列の探索や置換で利用
- 柔軟にパターンを記述できる
- 例
  - “000”の繰り返しを含む
  - 数字が偶数個連続する
  - 指定した文字列の後ろに数字が付いているファイル名
- 多くのプログラミング言語やテキストエディタで利用できる

例 1.1: ファイル名から日付部分を除く

```python
import re
fileList=[
    '1.1 Introduction_20201010.txt',
    '1.2 SetAndMappings_20211013.txt',
    '1.3 Relations_20100401.txt'
]
#日付以外の部分を取り出す
p: re.Pattern[str] = re.compile(r'(.*)_\d{8}(\.txt)')
for f in fileList:
    m: re.Match[str] | None = p.match(f)
    if m:
        filename: str = m.group(1)+m.group(2)
        print(filename)
```

```
1.1 Introduction.txt
1.2 SetAndMappings.txt
1.3 Relations.txt
```

例 1.2: ドメイン名を変更

```
1  mail_address_list:list[str]=[
2      'brown@example.com', 'page@hoge.com',
3      't2013@example.edu', 'kate@hoge.com',
4      's20235@foo.edu',    's19220@hoge.com'
5  ]
6  pattern = r'(\S+)@(\S+)'
7  p: re.Pattern[str] = re.compile(pattern)
8  for mail in mail_address_list:
9      m: re.Match[str] | None = p.match(mail)
10     if m:
11         domain = m.group(2)
12         if domain == 'hoge.com':
13             new_mail = m.group(1)+'@hogehoge.com'
14             print(new_mail)
15
```

Python での正規表現: ごく一部

- `.` 任意の文字と一致
- `\d` 数字と一致
- `\D` 数字以外と一致
- `\s` スペースやタブ、改行などの空白文字と一致
- `\S` 空白文字以外と一致
- `*` 0 回以上の繰り返し
- `+` 1 回以上の繰り返し

正規表現の定義: 基礎
Defining Regular Expressions: Fundamentals

- $a \in \Sigma$ に対して a は正規表現であり、その言語は $\{a\}$ である
  - 一文字からなる言語
- ϵ は正規表現であり、その言語は $\{\epsilon\}$ である
  - 長さゼロの文字列からなる言語
- $\emptyset$ は正規表現であり、その言語は $\emptyset$ である
  - 要素を持たない言語

正規表現の定義: 再帰
Defining Regular Expressions: Recursion

- α と β が、言語 L_α 及び L_β をそれぞれ表す正規表現のとき
  - $\alpha + \beta$ は $L_\alpha \cup L_\beta$ を表す正規表現
  - $\alpha\beta$ は $L_\alpha L_\beta$(連接:concatenation) を表す正規表現

$$L_\alpha L_\beta = \{uv | u \in L_\alpha, v \in L_\beta\} \tag{1.1}$$

  - α^* は Kleene 閉包: $L_\alpha^* = \bigcup_{k=0}^{\infty} L_\alpha^k$

$$L_\alpha^0 = \{\epsilon\}, L_\alpha^1 = L_\alpha, L_\alpha^{k+1} = L_\alpha L_\alpha^k \tag{1.2}$$

  - α^+ は正閉包：$L_\alpha^+ = \bigcup_{k=1}^{\infty} L_\alpha^k$

例 1.3: $a, b \in \Sigma$

- **a** は言語 $\{a\}$ を表す
- **b** は言語 $\{b\}$ を表す
- $\mathbf{a} + \mathbf{b}$ は言語 $\{a, b\}$ を表す
- **ab** は言語 $\{ab\}$ を表す
- $\mathbf{a}(\mathbf{a} + \mathbf{b})\mathbf{b}$ は言語 $\{aab, abb\}$ を表す
- $(\mathbf{a} + \mathbf{b})^*$ は、a と b からなる、長さゼロ以上の文字列全体からなる言語を表す

例 1.4:

$(0+1)1(0+1)$

$0(0+1)^*0$

正規表現と有限オートマトン
Regular Expressions and Finite State Automata

- 任意の正規表現を受理言語とする有限オートマトンを構成することができる
- 任意の有限オートマトンの受理言語を表す正規表現を構成することができる
- つまり、有限オートマトンの受理言語は正規表現で表される

正規表現から FA へ: 基礎的表現
From Regex to FA: Basic Representations

- **正規表現の構成を順を追って FA で表現**
- **基礎**:a, b $\in \Sigma$

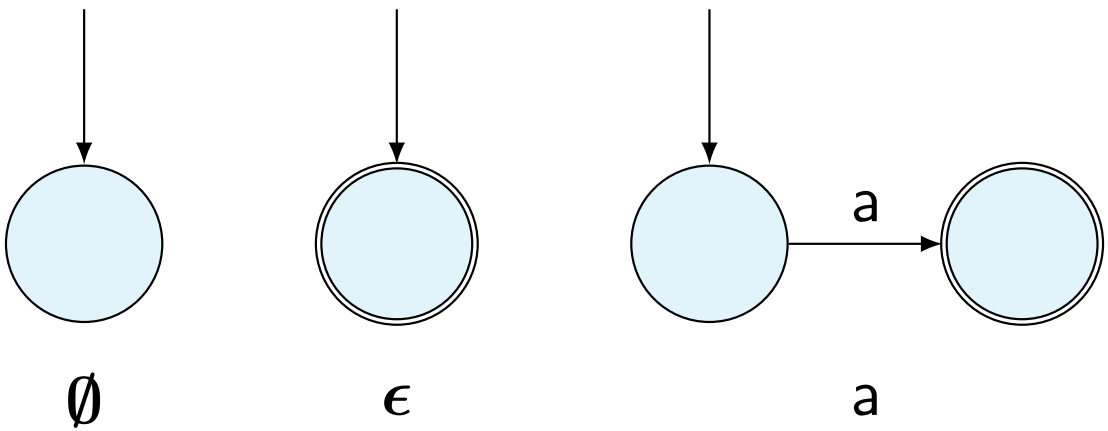

和、連接、Kleene閉包
Union, Concatenation, Kleene Closure

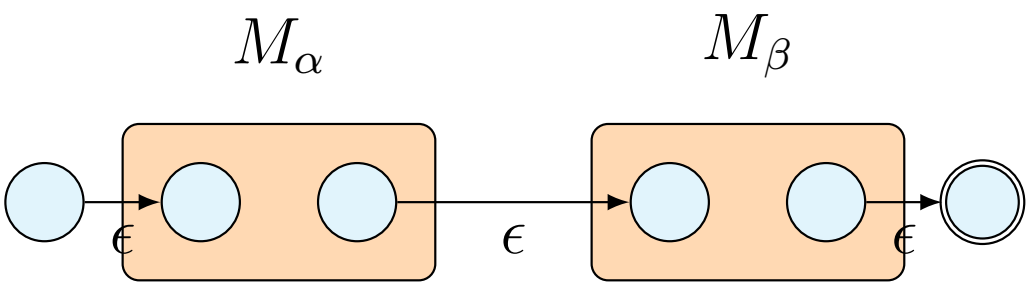

$\alpha\beta$

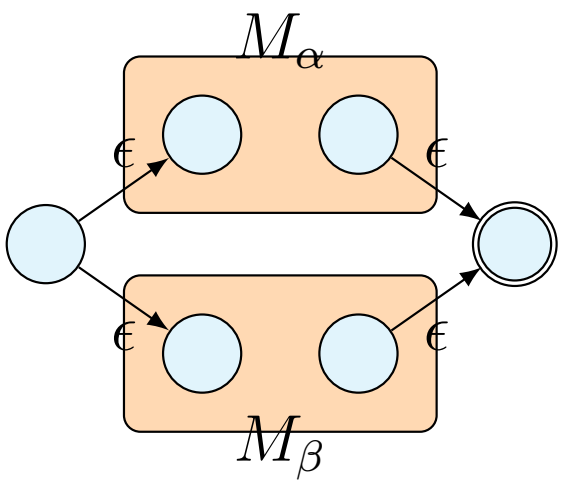

$\alpha + \beta$

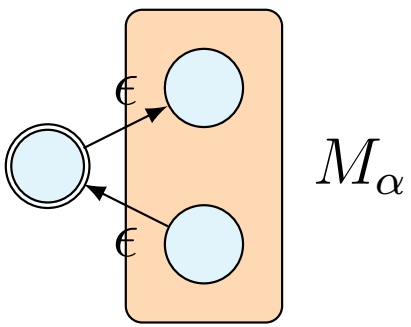

α^*

例 3.1: $\mathbf{0+1(0+1)^*}$

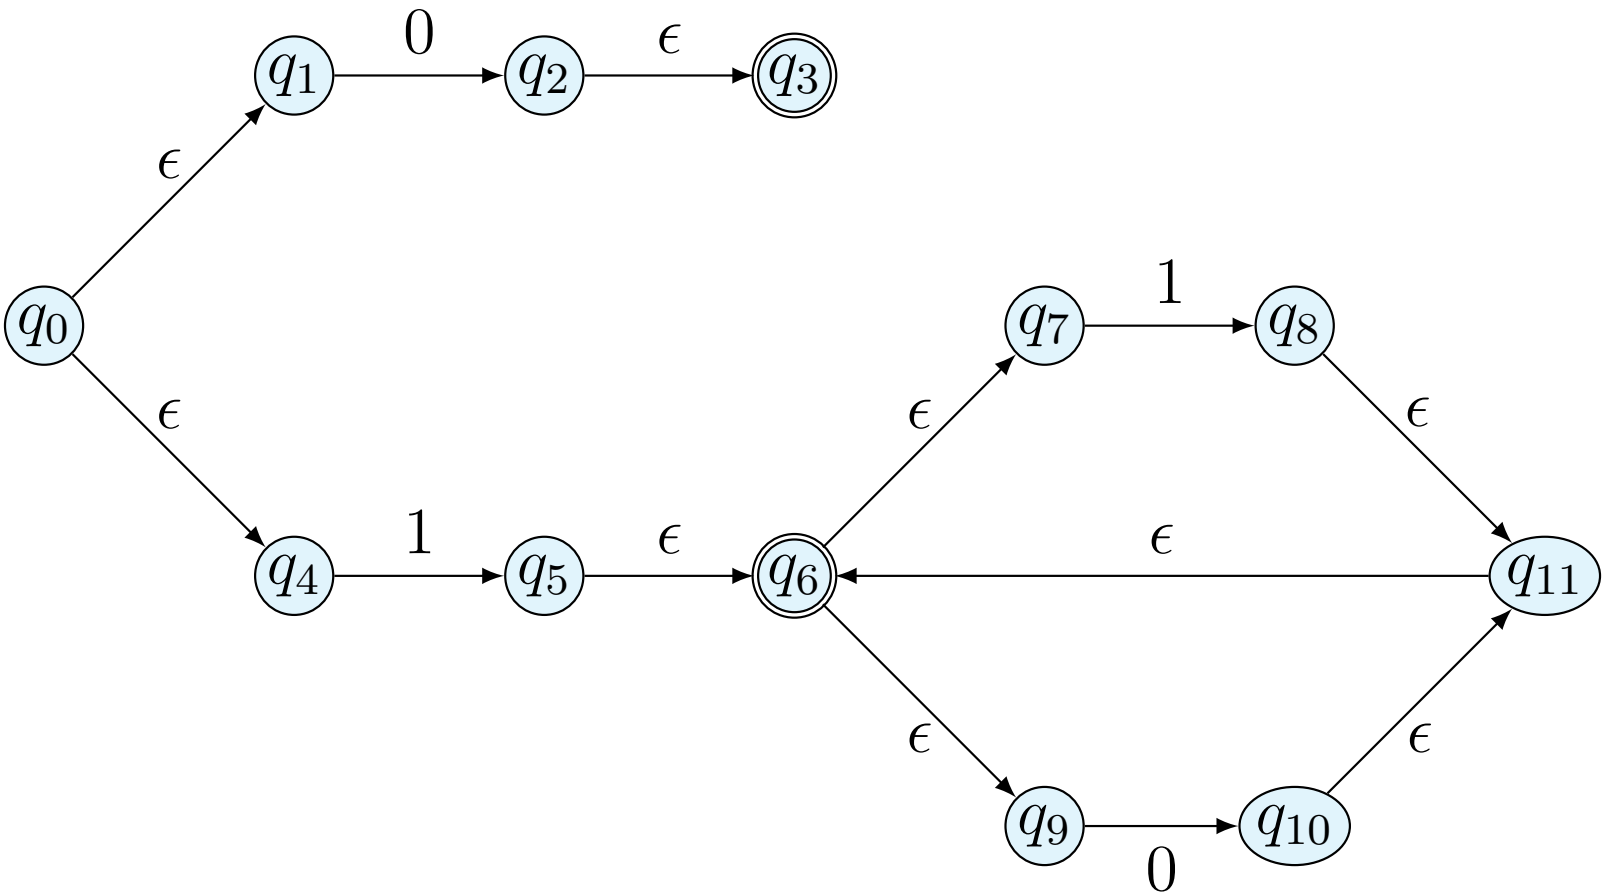

DFA へ変換: NFA to DFA

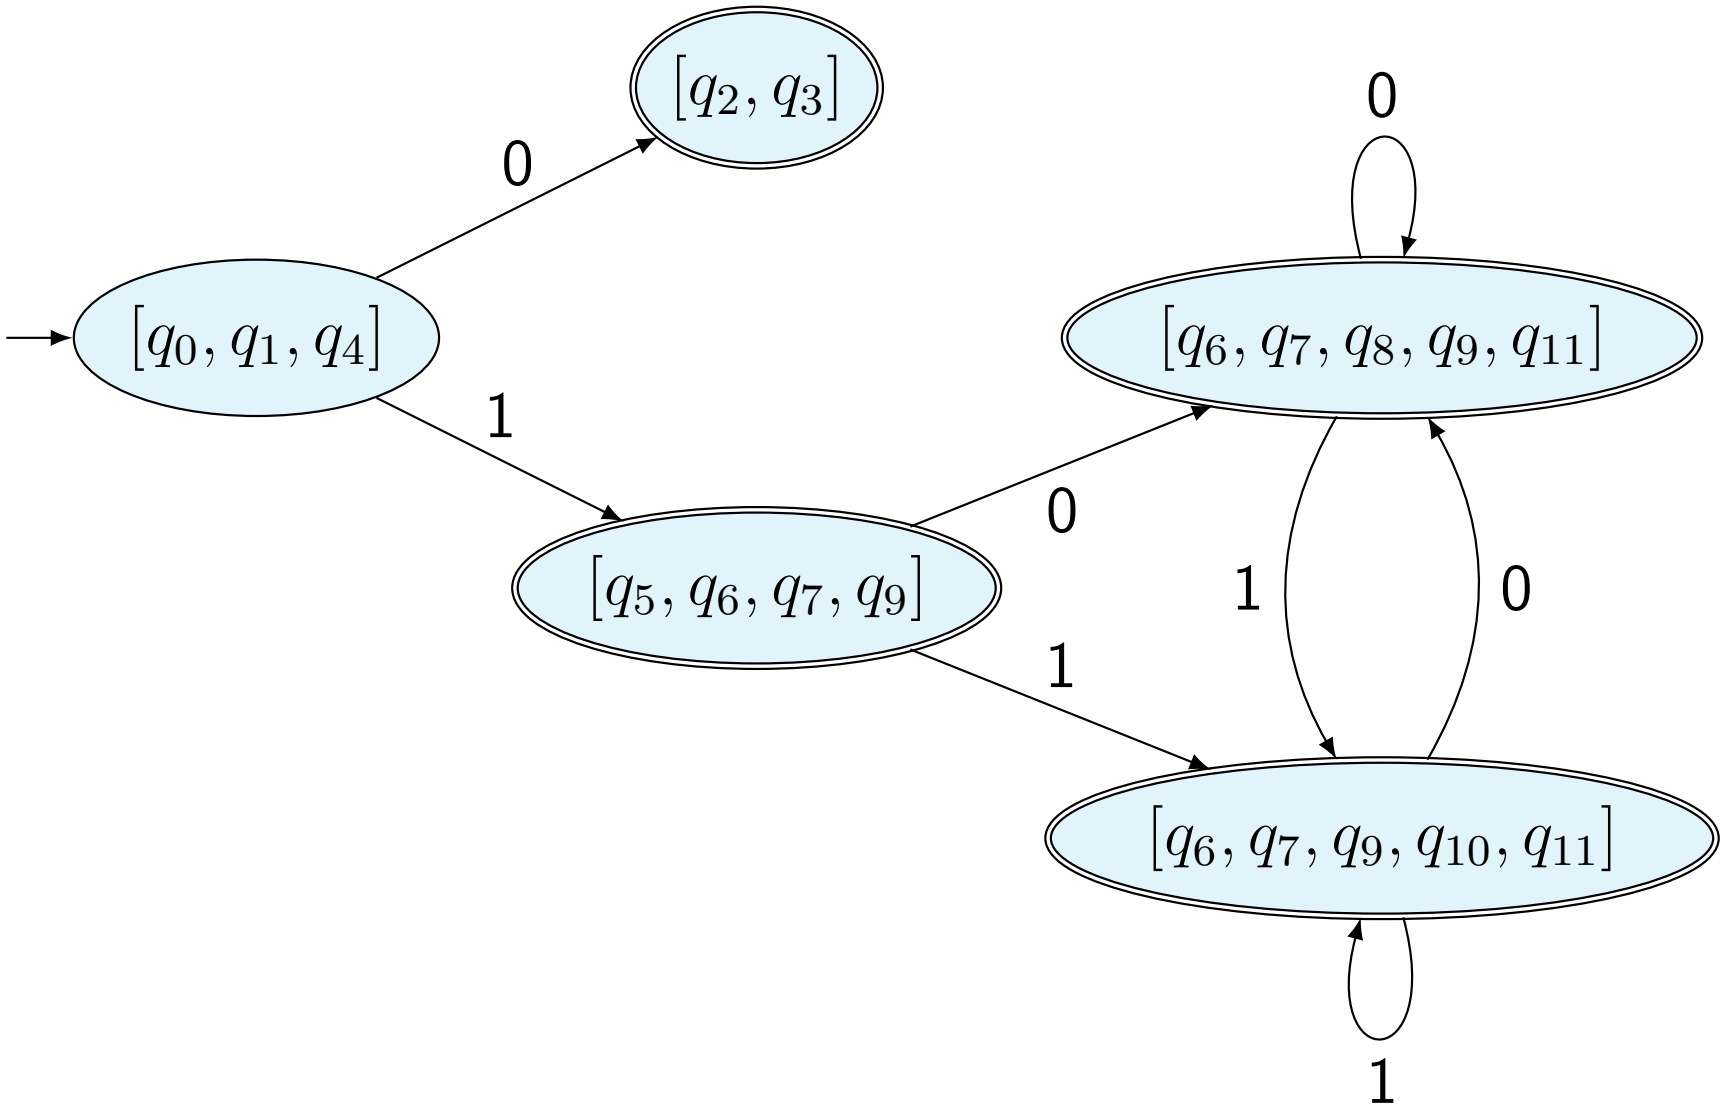

DFA を最小化: Minimizing DFA

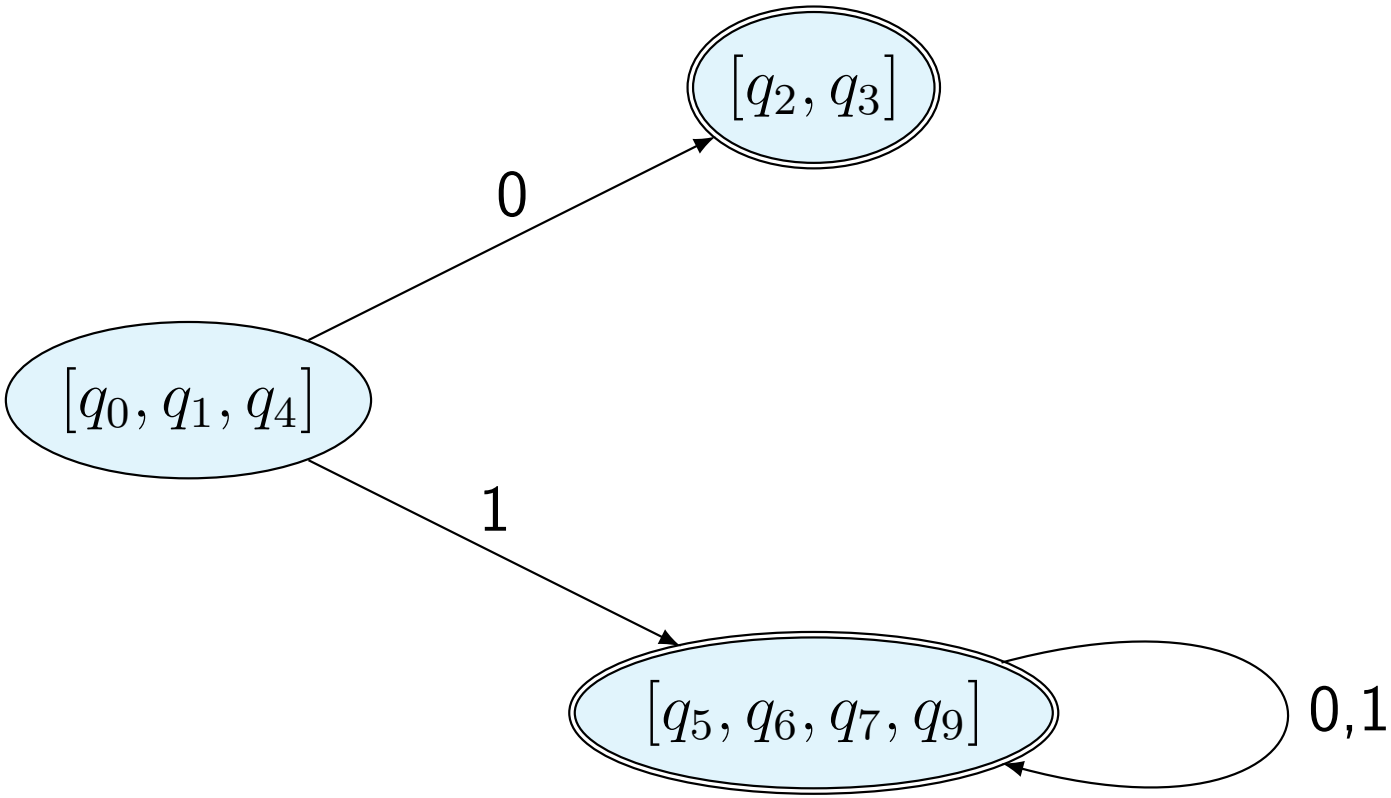

例 3.2: $(\mathbf{ab})^* \mathbf{aa} (\mathbf{a} + \mathbf{b})^*$

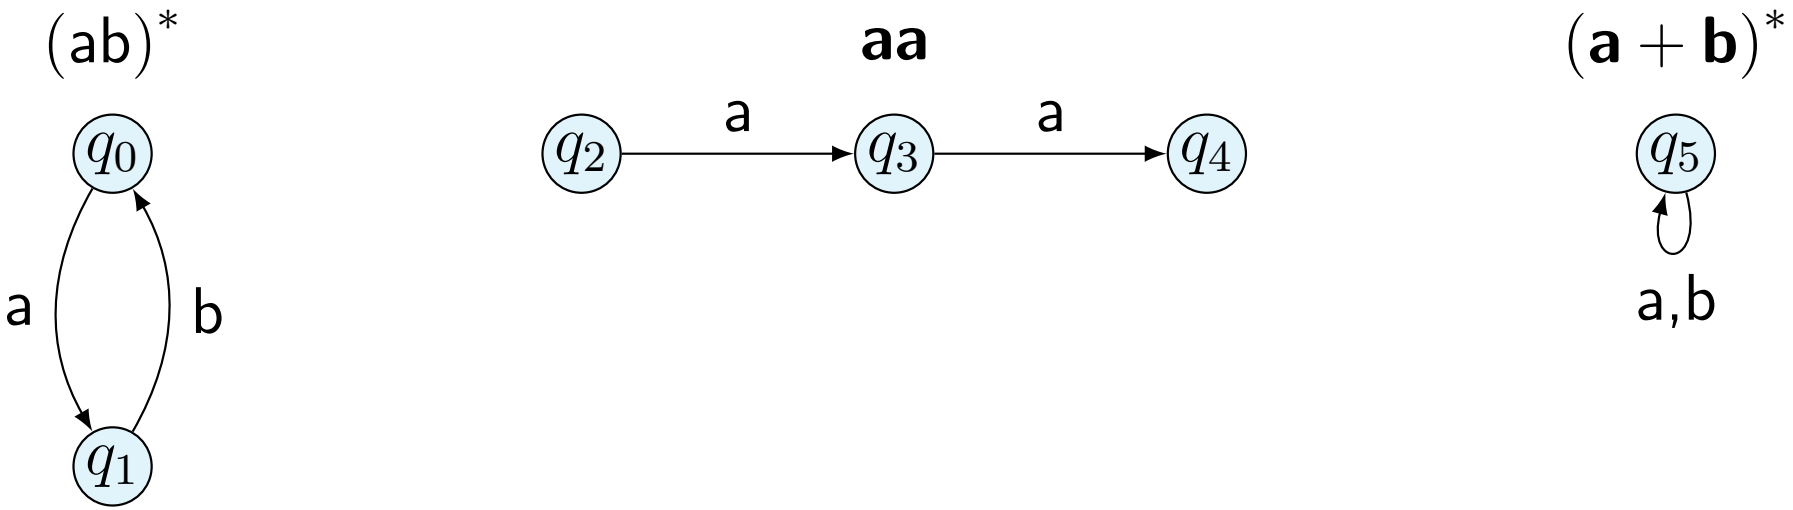

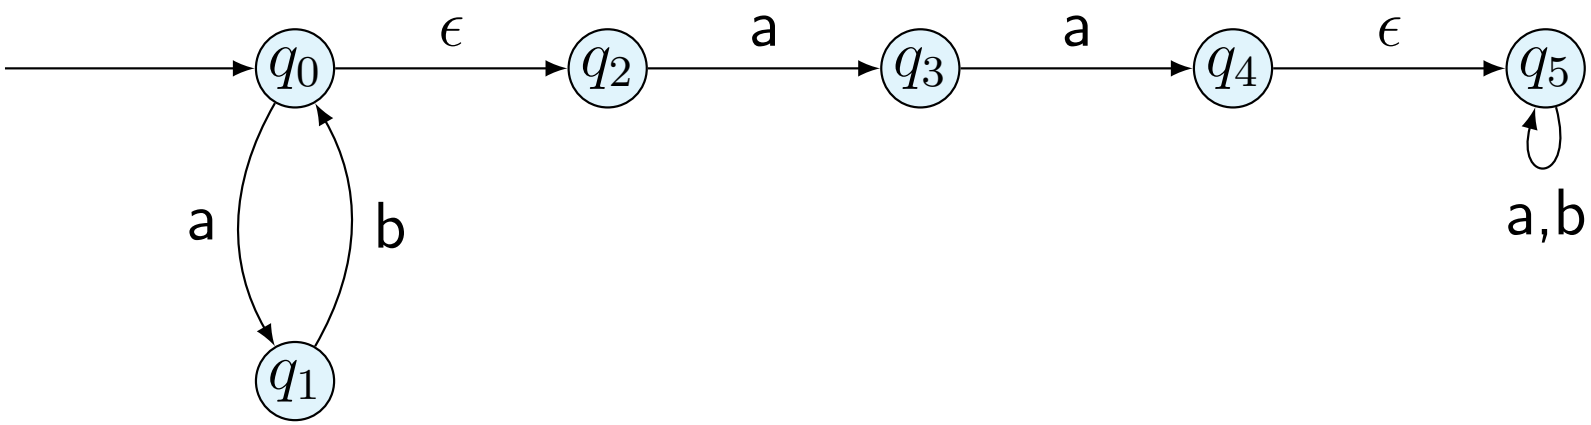
q_0
q_1
q_2
q_3
q_4
q_5
ϵ
a
a
ϵ
a
b
a,b

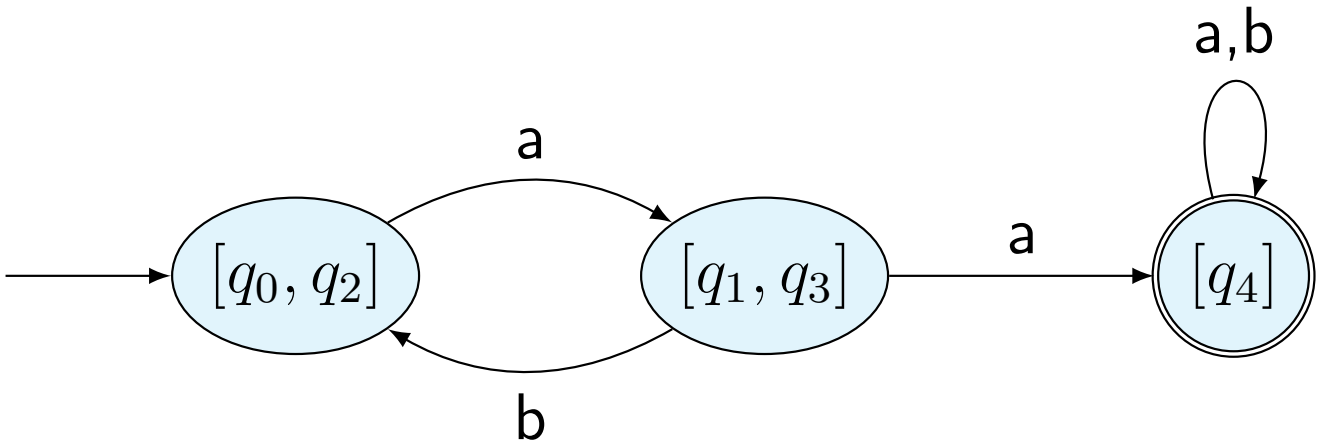
a,b
a
a
$[q_0, q_2]$
$[q_1, q_3]$
$[q_4]$
b

有限オートマトンの受理言語を正規表現で構成: From FA to Regex

- Step1: 新たに一つの終状態 q_f を追加し、それのみが終状態とする

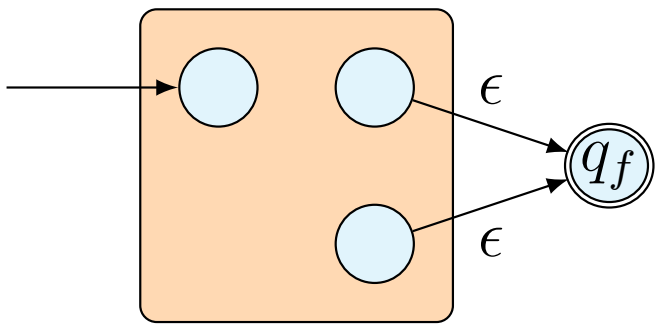

- step2: rule1,2,3 の順に適用する
- rule1: 同じ状態遷移を引き起こす入力に対して、正規表現の和を対応つける

- rule2: ループの遷移を次の遷移の前に連接する

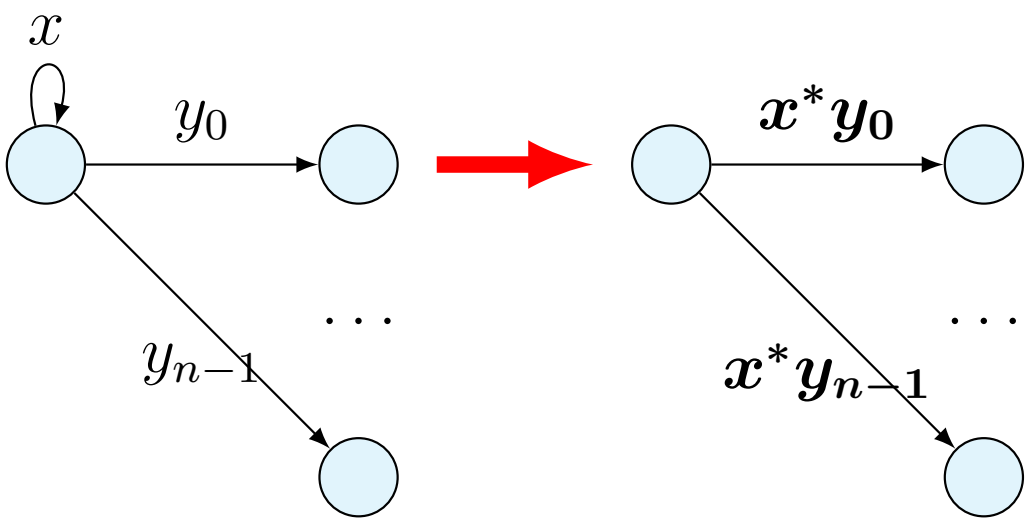

- rule3: 連続する遷移を、途中の状態を削除して連接とする

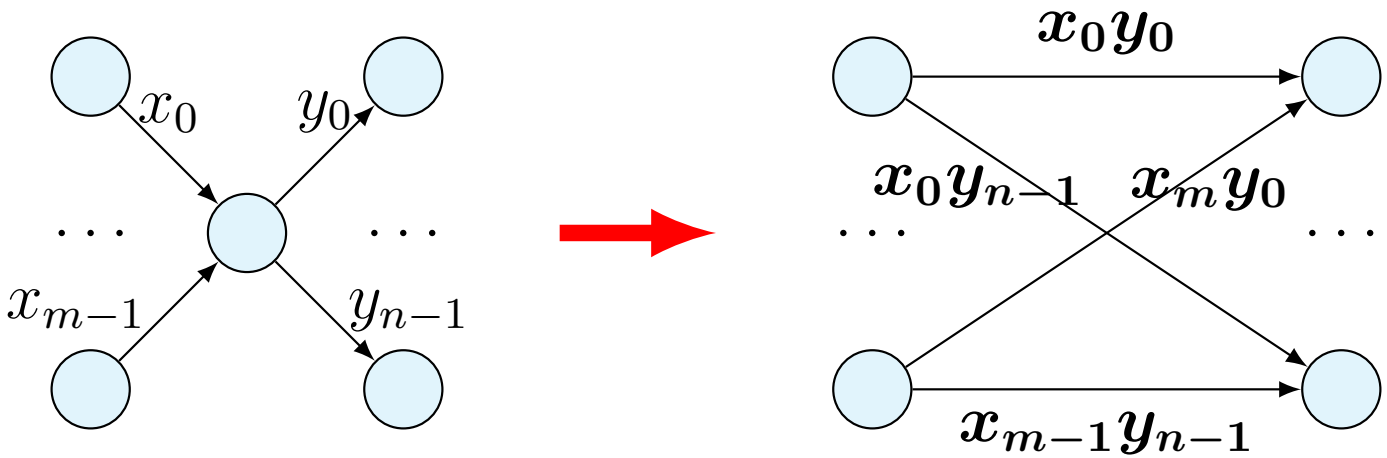

例 4.1:

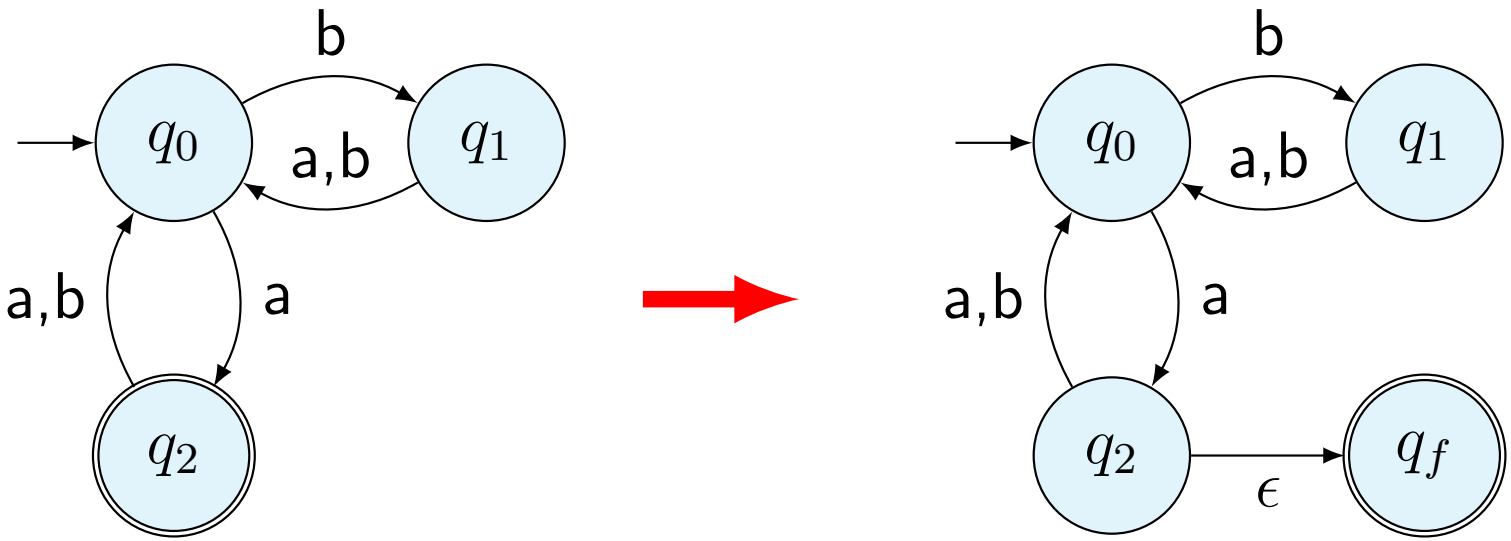

rule 1

同じ遷移を起こす入力を正規表現の和に変換

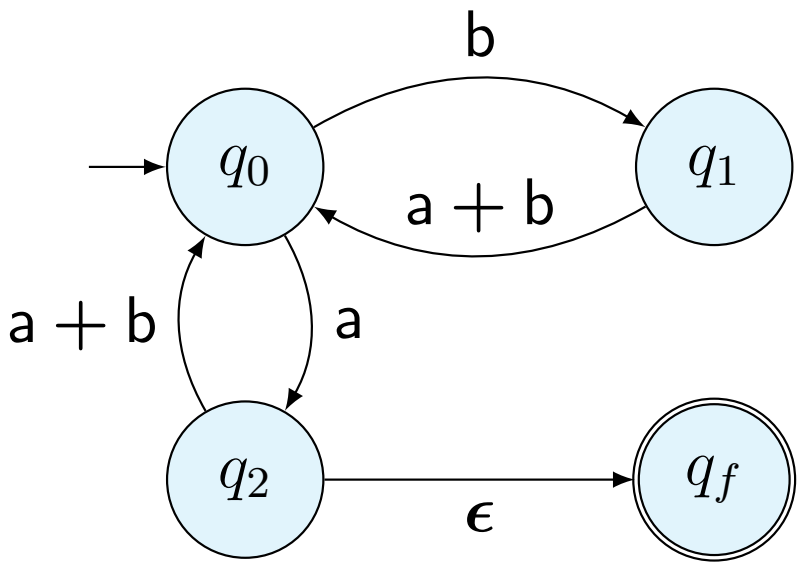

rule 3

- rule 2 に相当するループが
- q_0 から q_1 を経て、q_0 へ戻る経路をループに
-
- q_0 から q_2 を経て、q_0 へ戻る経路をループにするとともに、a_f への遷移を残す

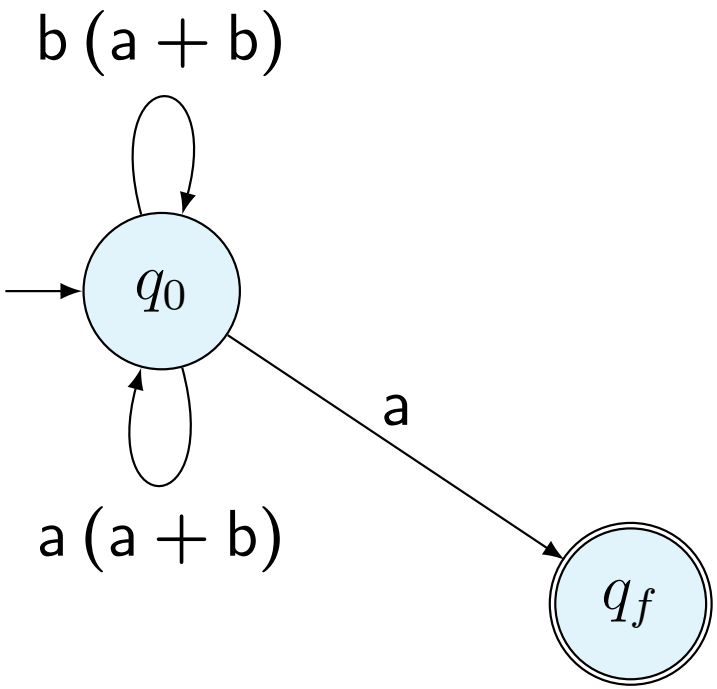

rule 1: 2回目

- q_0 の2つのループの表現の和を作る

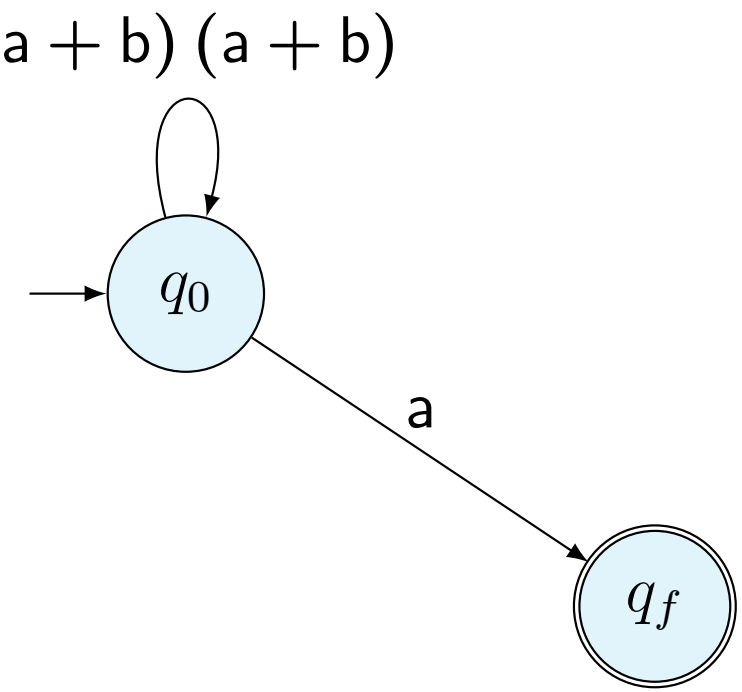

rule 2

- q_0 の２つのループの表現の和を作る

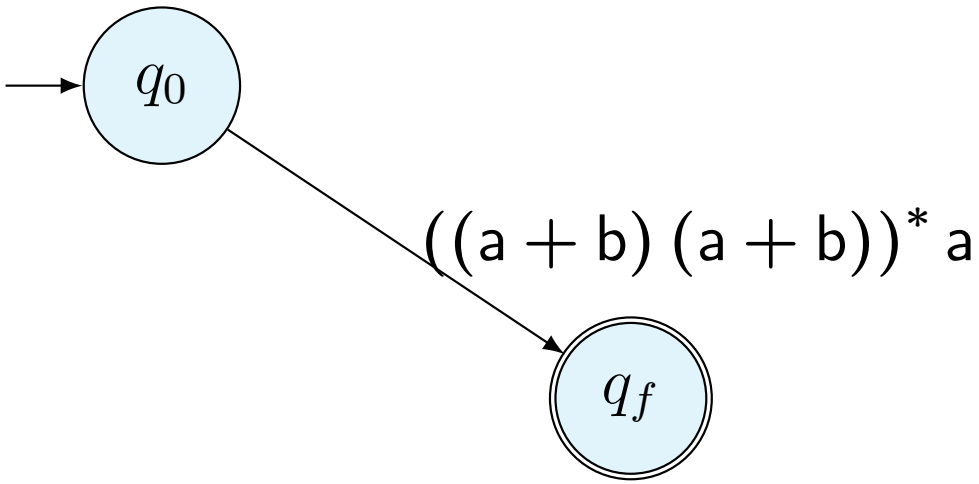

例 4.2:

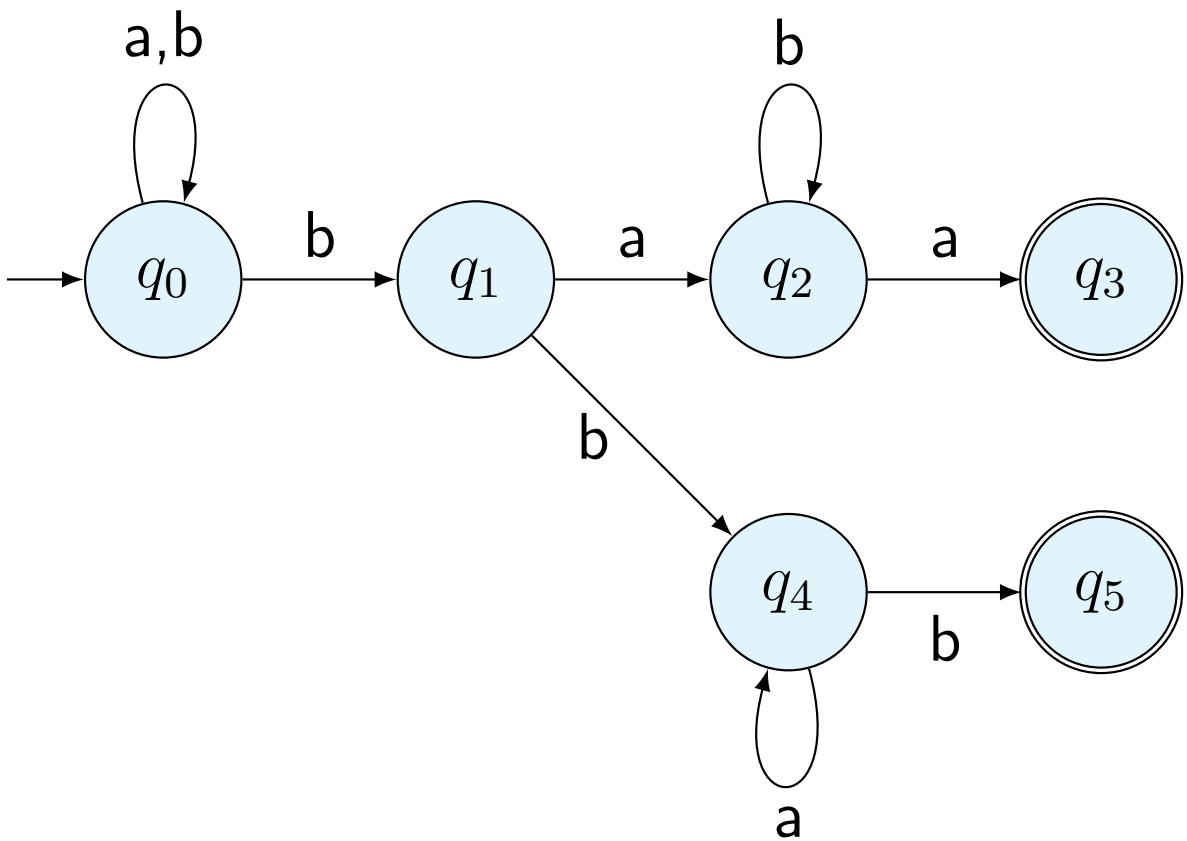

rule 1

q_f を追加し、rule1 を適用

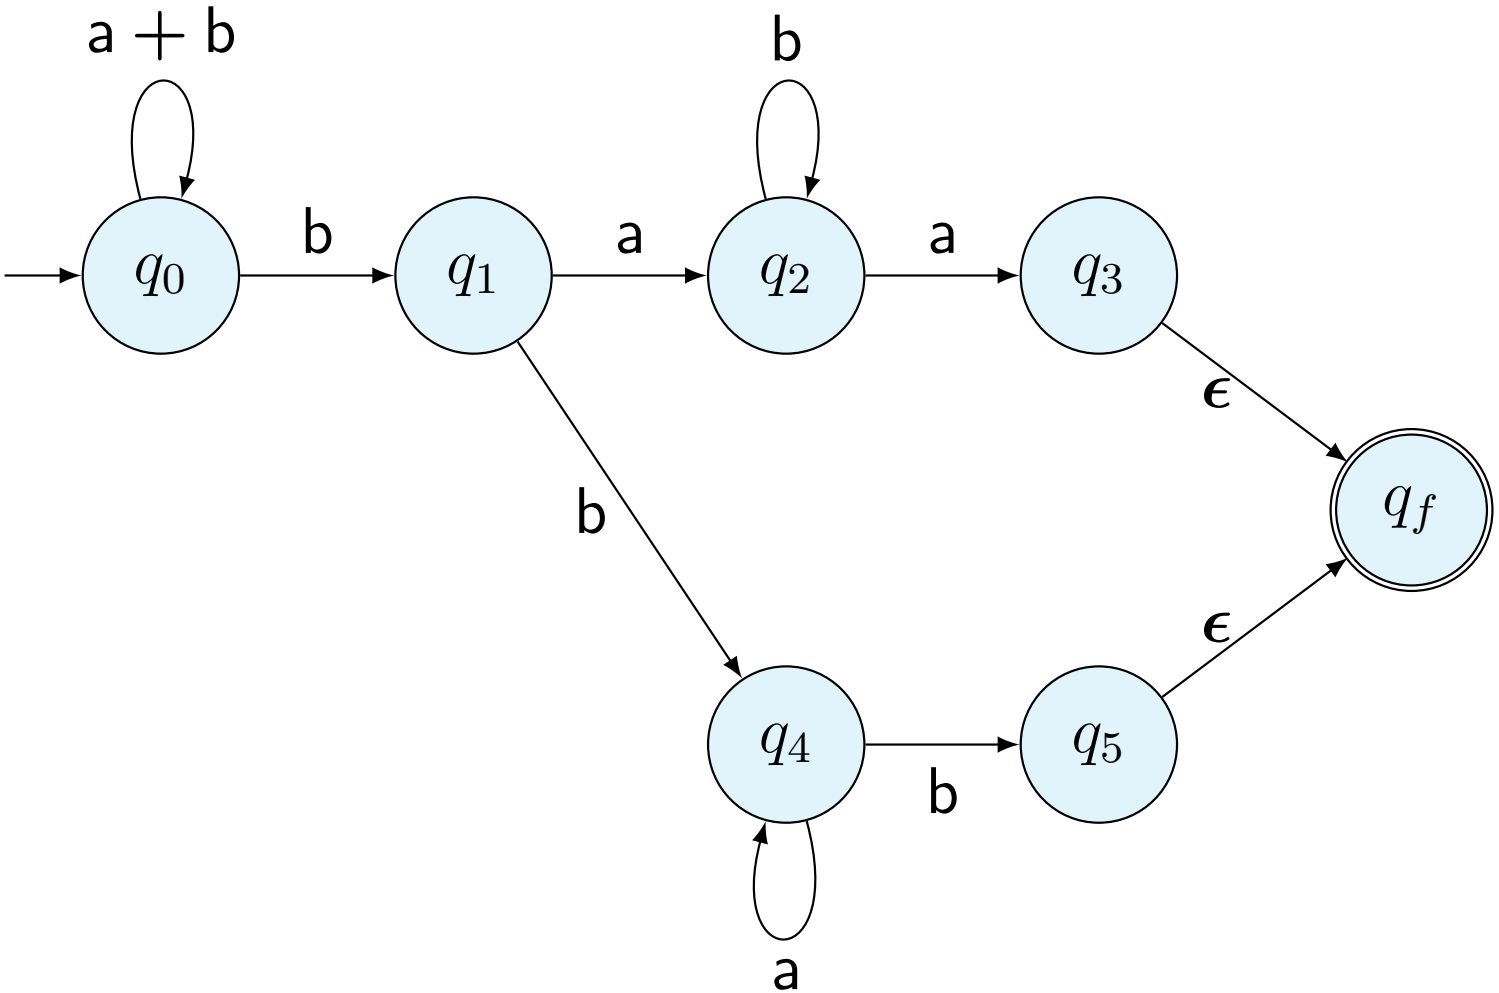

rule 2

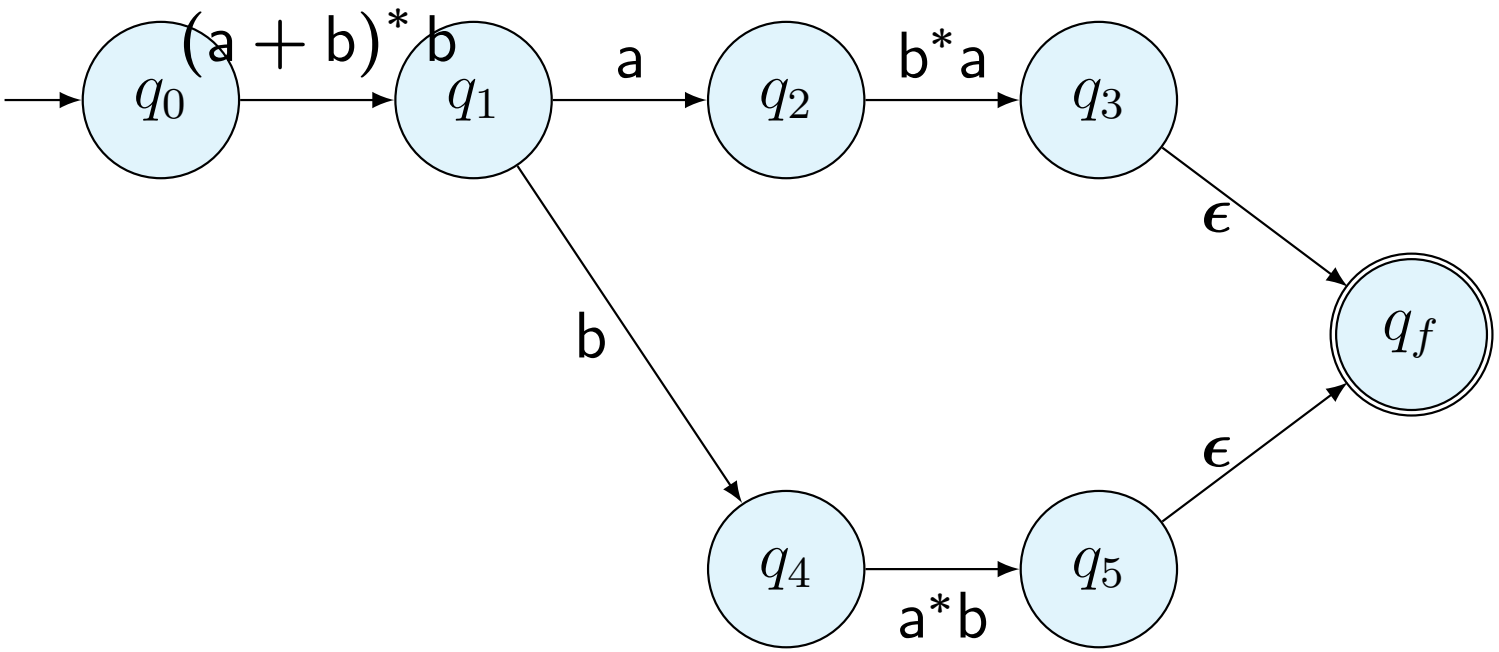

rule 3

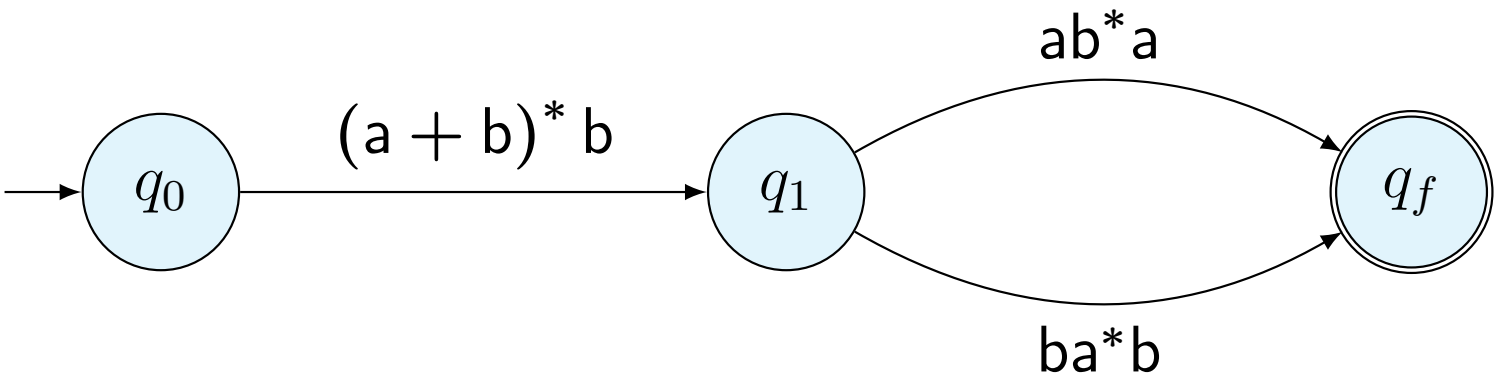

$$(\mathsf{a}+\mathsf{b})^*\,\mathsf{b}\,(\mathsf{ab}^*\mathsf{a}+\mathsf{ba}^*\mathsf{b})$$

正規表現に対する反復補題: Pumping Lemma

- L を正規言語とする
- L に対して、ある定数 n が存在し、$|w| \geq n$ となる任意の $w \in L$ に対し、以下のように $w = xyz$ と分解できる。
  - $y \neq \epsilon$
  - $|xy| \leq n$
  - $\forall k \geq 0,\ xy^k z \in L$

反復補題の証明

- L を正規言語とし、対応する DFA を M とする。
  - $L = L(M)$
  - M の状態数を n とする

$$w = a_1 a_2 \cdots a_m \in L,\ (m \geq n,\ a_i \in \Sigma)$$
$$p_i = \delta(q_0, a_1 a_2 \cdots a_i),\ (p_0 = q_0)$$

- $p_0, p_1, \cdots, p_n$ には少なくとも一つの状態が 2 回以上現れる

$$p_i = p_j,\ (0 \leq i < j \leq n)$$

- $w = xyz$ と分解する

$$x = a_1 a_2 \cdots a_i, \quad y = a_{i+1} a_{i+2} \cdots a_j, \quad z = a_{j+1} a_{j+2} \cdots a_m$$
$$|x| = i \geq 0, \quad |y| = j - i > 0, \quad |z| = m - j \geq 0$$

- $xy^k z \in L \ (0 \leq k)$

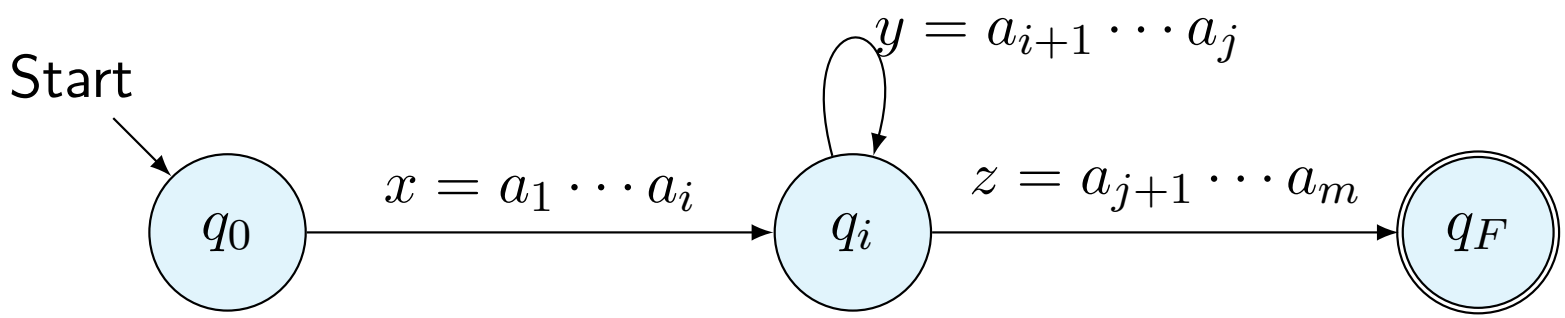

反復補題の応用

$L_{01} = \{0^m 1^m | m \geq 0\}$ は正規言語でない

- L_{01} が正規言語であると仮定
- 反復補題に現れる n に対して、$w = 0^n 1^n$ を考える
- $w = xyz$、$|xy| \leq n$ より、$y = 0^k$ $(1 \leq k \leq n)$

$$xy^0 z = xz = 0^{n-k} 1^n \notin L_{01}$$

- L_{01} は正規言語でない